

Ciência de dados: Uma abordagem prática

Professor Mestre: Adilson Lopes Khouri

6 de agosto de 2018

Sumário

- 1 Apresentação
- 2 Processo de Data Science
- 3 PagSeguro
- 4 NuvemShop
- 5 Amostragem - principais erros
- 6 Engenharia de features
- 7 Overview de modelos
- 8 Treinamento de modelos
- 9 Ferramentas
- 10 Agradecimentos
- 11 Contato

Pessoal

- Adilson Khouri, jogador de Magic the Gathering, nerd, apaixonado por computação, machine learning, brasileiro mas não sei jogar futebol nem sambar!



Figura: Eu na Argentina!

Formação Acadêmica

- Bacharel em Sistemas de Informação (2011 - USP)
- Mestre em Sistemas de Informação (2016 - USP)
- Doutorando em Sistemas de Informação (cursando - USP)

Experiência de Mercado

- Programador na consultoria Arbit (2010-2011)
- Programador Itaú-Unibanco (2011-2013)
- Cientista de dados Sr. PagSeguro (2016 - 2018)
- Cientista de dados Sr. NuvemShop (Atual)
- Professor de Programação - SENAC (Atual)

Processo de Data Science

Data Science Lifecycle

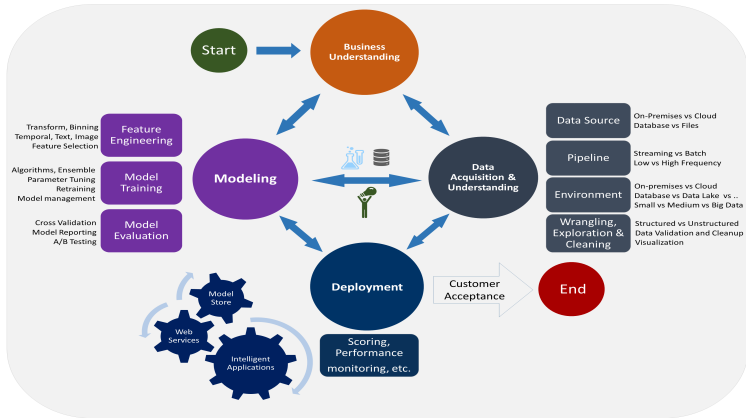


Figura: Obtido em: <https://docs.microsoft.com/en-us/azure/machine-learning/team-data-science-process/overview>

PagSeguro: Risco e modelagem

- Atuação em modelo para previsão de chargeback em transações financeiras
- Criação de regras de risco para incrementar o modelo
- Clusterização de vendedores para agrupar por tipo de risco de chargeback
- Criação de árvore CART para determinar regras novas para aumentar o grau de discriminação do modelo
- Criação de modelo para detecção de anomalias em clientes - baseado em intervalo de confiança e aproximação por Gaussiana

PagSeguro: Consultor interno de data science

- Relatório de market share para área de produtos da empresa determinar onde investir mais dinheiro em propaganda
- Relatório para avaliação de carrinhos abandonados da empresa

Pagamentos

- Avaliação de variáveis para discriminar clientes (quais vão, ou não, ativar a assinatura)
- Levantamento de variáveis, treinamento e validação de modelo para prever pagamento de assinatura
- Palestra sobre erros comuns em amostragem
- Automatização de extrator de dados (12h semanais para 20min semanais)

Amostras viesadas

- Precisamos de informação precisa e sem viés para tomarmos boas decisões.
- Se você “cria conhecimento” ou “toma decisões” usando informação viesada você não está sendo # datadriven
- A probabilidade de tomar decisões ruins aumenta... e decisões ruins costumam ser caras...

processo de KDD




Figura: Processo de KDD

- Se você cometer um erro durante a etapa de: “seleção” os passos seguintes e suas conclusões estarão erradas.

Amostragem 101




Figura: Overview de amostragem

- O subconjunto (amostra) de elementos deve ser representativa da população.

Bias de auto seleção

- Suponha um estudo estatístico sobre detalhes íntimos da sexualidade de estudantes em universidades. Algumas pessoas provavelmente vão mentir.
- Uma pesquisa online sobre quem gosta de usar computador.
- Em ambos as pessoas selecionadas vão ter seus comportamentos diferentes da população geral.

Undercoverage Bias

- Digest em 1936 fez uma pesquisa eleitoral que previa vitória larga do candidato Landon em relação ao candidato Roosevelt. Roosevelt ganhou com uma margem larga, a pesquisa era feita por telefone, na época pessoas pobres (maioria da população que era a favor de Roosevelt) não tinha telefone. Essa foi uma das causas do erro estatístico.

Survivorship Bias

- Ocorre quando as observações estudadas no fim da investigação são não aleatórias em comparação as presentes no começo da observação.

Survivorship Bias

- Exemplo da segunda guerra mundial (tiros em avião)

Engenharia de features

- Modelos usam muitas variáveis para tomar decisões
- Encontrar boas variáveis é parte fundamental para um modelo
- Citar exemplo de variáveis de transações financeiras
- Citar exemplo de variáveis de pagamento de assinaturas
- Citar exemplo de um classificador de brasileiros e peruanos

Modelos



Figura: Brincadeira, cada modelo trabalha internamente de uma forma distinta!

Modelos

- Modelos tomam decisões baseados em diversas variáveis para, entre outras coisas, classificar dados
- Quem são peruanos e quem são brasileiros nessa sala?
- Há modelos para classificar em duas classes ou mais.




Figura: Exemplo de árvore de decisão para sair de casa

Treinamento

- O processo de treinamento é único para cada modelo mas a forma como se treina um modelo é parecida
- Os dados são divididos em treino (70%) e teste (30%)
- O conjunto de treino é apresentado ao modelo com os rótulos de cada observação
- Tipicamente usa-se uma validação cruzada para treinar o modelo

Validação

- O modelo é validado com o conjunto de teste, o qual não deve exibir os rótulos para o modelo
- Alguma métrica de validação de modelos é usada, por exemplo,

precisão $\frac{VP}{VP + FP}$

		PREDITO	
		Classe A	Classe B
VERDADEIRO	Classe A	VP	FN
	Classe B	FP	VN

Figura: Obtido no link: Scielo

Ferramentas

- Na teoria pode-se usar qualquer linguagem de programação para trabalhar com Data Science
- Na prática usa-se, majoritariamente, a plataforma R e a linguagem python (com alguns pacotes científicos)
- <http://scikit-learn.org/stable/> (biblioteca Python)
- <https://www.r-bloggers.com> (blog de plataforma científica)

Hands on

- Treinar modelo em R com os alunos
- Treinar modelo em PYTHON com os alunos

Fim!

Agradeço a professora mestra Ana Roccio Cardenas Maita, ao meu orientador professor Dr. Luciano Antonio Digiampietri, aos meus pais e a Deus.

Contato

- email: adilson.khoury.usp@gmail.com
- phone: +55 11 9444-26191
- Linkedin: <https://www.linkedin.com/in/adilson-khoury-51893918/>
- Lattes: <http://lattes.cnpq.br/2654721135214993>